



تشخیص ارقام دست‌نویس

در این تمرین، می‌خواهیم به کمک شبکه‌های عصبی مسئله classification تصاویر ارقام دست‌نویس را حل کنیم. مجموعه داده‌های مورد استفاده در این مسئله، برگرفته از مجموعه داده‌های MNIST است که برای این تمرین، اندکی مورد پردازش قرار گرفته است. چند نمونه از تصاویر این مجموعه داده در شکل ۱ نشان داده شده‌است. این مجموعه داده شامل ۹۸۰۰۰ تصویر ۲۸ در ۲۸ برای آموزش شبکه (با برچسب) و ۲۱۰۰۰ تصویر (بدون برچسب) برای ارزیابی مدل و نمره‌دهی است.



شکل ۱: چند نمونه از تصاویر مجموعه داده مسئله

به همراه این فایل، یک فایل جویپتر نوت‌بوک نیز در اختیارتان قرار گرفته است که بایستی پیاده‌سازی و آموزش شبکه عصبی خود را در آن انجام دهید. آن چه تحویل خواهید داد، فایل نوت‌بوک مذکور و فایل prediction داده‌های ارزیابی است. فایل hw4_helper.py نیز حاوی توابع کمکی برای دریافت دیتاست و ذخیره prediction است که در ادامه نحوه استفاده از آن شرح داده شده‌است.

دریافت داده‌ها

برای دریافت داده‌ها می‌توانید از توابع زیر استفاده کنید:

```
1 import hw4_helper
2 x_train, y_train = hw4_helper.get_train_data()
3 x_test = hw4_helper.get_test_data()
```

این توابع، برای اولین بار فایل دیتاست را دانلود کرده و در فولدر data_cache ذخیره می‌کنند. در دفعات بعدی چون فایل‌ها در آن مسیر موجود اند، تصاویر بدون دانلود مجدد از همان‌جا load می‌شوند. در صورت بروز هرگونه مشکل با توابع مذکور، می‌توانید فایل x_train، y_train و x_test را دانلود کرده و با استفاده از تابع np.load('path/to/file') آن‌ها را load کنید.

نکته مهم: برای آموزش شبکه خود فقط و فقط از x_train و y_train استفاده کنید.

طراحی مدل

پیشنهاد می‌شود برای طراحی مدل خود، از کتابخانه‌های **Tensorflow**، **PyTorch** یا **Keras** استفاده کنید. مدل شما باید یک batch از تصاویر را که ابعاد آن $28 \times 28 \times B$ است را دریافت کرده و به ازای هر تصویر، یک بردار 10 بعدی بعنوان خروجی برگرداند که هر عنصر آن، احتمال هریک از برچسب‌ها (ارقام ۰ تا ۹) باشد. (ابعاد خروجی باید $10 \times B$ باشد).

ساده‌ترین مدلی که می‌توانید طراحی کنید، فقط شامل لایه‌های **Fully Connected** است. در این حالت، باید تصاویر خود را بصورت یک آرایه یک‌بعدی (با $28 \times 28 = 784$ عنصر) به مدل بدهید. در مدل نیز کفایت بصورت پشت سر هم، لایه‌های خطی را با تابع فعال‌سازی **ReLU** قرار دهید. در آخرین لایه (که شامل ۱۰ نرون است) نیز باید از تابع فعال‌سازی **Softmax** استفاده کنید. این تابع مجموع خروجی‌های هر نمونه را برابر ۱ قرار می‌دهد تا بتوان به هر یک از عناصر آن بعنوان احتمال نگاه کرد.

با استفاده از شبکه‌های **Fully Connected** می‌توانید به دقت مورد انتظار برای دریافت نمره کامل در این مسئله برسید. اما برای دقت‌های بالاتر و دریافت نمره امتیازی، بهتر است از شبکه‌های عصبی کانولوشنی استفاده کنید. برای این کار، ابتدا توسط لایه‌های کانولوشنی دوبعدی و تابع فعال‌سازی **ReLU**، ابعاد تصویر را کاهش، و تعداد کانال‌های آن را افزایش دهید. (برای کاهش ابعاد تصاویر، هم می‌توانید از لایه‌ی کانولوشنی با **stride** برابر ۲ استفاده کنید، هم می‌توانید از لایه‌های **Pooling** مثل **Max Pooling** استفاده کنید.) پس از کاهش ابعاد تصاویر و افزایش کانال‌های آن به اندازه کافی، آن را بصورت یک‌بعدی در آورده و توسط یک شبکه **Fully Connected**، مشابه چیزی که بالاتر شرح داده شد خروجی را تولید کنید.

همچنین برای جلوگیری از **overfitting**، می‌توانید از لایه‌های **Dropout** و **Batch Normalization** در میان لایه‌های شبکه خود استفاده کنید. در **این لینک**، می‌توانید یک پیاده‌سازی بسیار ساده از یک شبکه عصبی کانولوشنی در کتابخانه **PyTorch** را مشاهده کنید.

تابع هزینه و روش بهینه‌سازی

برای مسئله **classification** چند کلاسه، عموماً از تابع هزینه **cross-entropy** استفاده می‌شود. روش‌های بهینه‌سازی متنوعی نیز قابل استفاده اند، که از جمله آن‌ها می‌توان به **Adam** و **SGD** اشاره کرد.


آموزش شبکه

برای آموزش شبکه خود، بخش کوچکی از داده‌های آموزشی (مثلاً ۱۰ درصد) را برای اعتبارسنجی (**validation**) در نظر بگیرید. (می‌توانید از **این** تابع استفاده کنید.) سپس در هر **epoch**، داده‌های آموزشی را به تعدادی **batch** تقسیم کرده، و هر یک را به مدل دهید. با استفاده از تابع هزینه، هزینه خروجی محاسبه شده را بدست آورید و با استفاده از روش بهینه‌سازی، وزن‌های مدل خود را به‌روزرسانی کنید. علاوه بر محاسبه هزینه مجموع هر **epoch**، دقت (نسبت تعداد تشخیص‌های درست به کل تصاویر) را نیز محاسبه کرده و در یک لیست ذخیره کنید.

در هر **epoch** پس از آموزش شبکه، هزینه و دقت را روی داده‌های اعتبارسنجی نیز انجام دهید و نتایج را ذخیره کنید. توجه کنید که در اعتبارسنجی، به هیچ وجه از بهینه‌سازی استفاده نکنید.

رسم نمودار آموزش شبکه

مطابق شکل ۲، نمودارهای روند پیش‌روی هزینه و دقت مدل روی داده‌های آموزشی و اعتبارسنجی مدل را رسم کنید.



شکل ۲: نمودار آموزش شبکه

نمایش نمونه‌های اشتباه تشخیص داده شده

مطابق شکل ۳، ۱۰ نمونه از مجموعه داده‌های اعتبارسنجی خود را که مدل‌تان به اشتباه آن‌ها را تشخیص می‌دهد، به همراه برچسب واقعی و برچسبی که مدل به آن می‌زند، نمایش دهید.



شکل ۳: نمونه‌های اشتباه تشخیص داده شده

اجرای مدل روی داده‌های تست و ذخیره خروجی آن در فایل

در نهایت، مدل با کمترین هزینه اعتبارسنجی را انتخاب کرده، و خروجی آن به ازای داده‌های تست بدست آورید. خروجی احتمال را با استفاده از تابع `argmax` به برچسب تبدیل کنید. (به ازای هر نمونه، یک عدد بین ۰ تا ۹ به آن نسبت دهید). سپس بردار یک‌بعدی حاصل را با استفاده از تابع زیر ذخیره کنید.

```
hw4_helper.export_prediction(prediction)
```

این تابع، فایل `prediction.npy` را در کنار نوت‌بوک می‌سازد. این فایل را به همراه نوت‌بوک نهایی به فرمت `zip` در آورده و در کوئرا بارگذاری کنید.